
11_Projected_Gradient_Descent

Martin Reißel

27. Juni 2022

Inhaltsverzeichnis

1	Projected Gradient-Descent	1
1.1	Überblick	1
1.2	Grundlagen	1
1.3	Konvergenz	6
1.3.1	Vorüberlegungen	6
1.3.2	Lipschitz-Stetigkeit	6
1.3.3	L -Glattheit	7
1.3.4	μ -Konvexität	9
1.4	Projektionsoperatoren	10
1.4.1	Kugel in der 2-Norm	10
1.4.2	Nicht negativer Kegel	10
1.4.3	Kugel in der 1-Norm	11
1.5	Beispiel Tomographie	18
1.6	Zusammenfassung	20

1 Projected Gradient-Descent

1.1 Überblick

Bisher haben wir Gradient-Descent für nicht restringierte Optimierungsprobleme untersucht. In diesem Abschnitt modifizieren wir Gradient-Descent so, dass wir es auch auf eine bestimmte Klasse von restringierten Optimierungsproblemen anwenden können. Dazu kombinieren wir Gradient-Descent mit einer geeigneten Projektion auf die zulässige Parametermenge $X \subset \mathbb{R}^d$.

1.2 Grundlagen

In den Beispielen oben haben wir bereits Projected-Gradient-Descent benutzt, um für $f \in C^1(\mathbb{R}^d)$ restringierte Optimierungsproblem näherungsweise zu lösen:

$$\begin{aligned}x_* &= \operatorname{argmin}_{x \in X} f(x), \quad X \subset \mathbb{R}^d \\y_{t+1} &= x_t - \gamma_t f'(x_t) \\x_{t+1} &= \operatorname{argmin}_{x \in X} \|x - y_{t+1}\|\end{aligned}$$

Ist x_{t+1} überhaupt wohldefiniert (Existenz, Eindeutigkeit)?

Satz: Ist V ein Hilbert-Raum, $\emptyset \neq X \subset V$ konvex und abgeschlossen, dann existiert genau ein $y \in X$ (die Projektion von x auf X) mit

$$\|x - y\| = \inf_{z \in X} \|x - z\|.$$

Für $x \in V$ ist $y \in X$ die zugehörige Projektion, genau dann wenn

$$(x - y, z - y) \leq 0 \quad \forall z \in X.$$

Beweis:

- Existenz von y :

- ▶ sei $y_i \in X$ eine Folge mit

$$\lim_{i \rightarrow \infty} \|x - y_i\| = \inf_{z \in X} \|x - z\| =: d$$

- ▶ wegen $\|v\|^2 = (v, v)$ gilt die Parallelogrammgleichung

$$\|u + v\|^2 + \|u - v\|^2 = 2(\|u\|^2 + \|v\|^2)$$

also

$$\|u - v\|^2 = 2(\|u\|^2 + \|v\|^2) - \|u + v\|^2$$

- ▶ setzen wir nun

$$u = y_i - x, \quad v = y_j - x$$

dann folgt

$$\|y_i - y_j\|^2 = 2(\|y_i - x\|^2 + \|y_j - x\|^2) - \|y_i + y_j - 2x\|^2$$

- ▶ wegen

$$\|y_i + y_j - 2x\|^2 = 4 \left\| \underbrace{\frac{y_i + y_j}{2}}_{\in X} - x \right\|^2 \geq 4d^2$$

gilt

$$\|y_i - y_j\|^2 \leq 2(\|y_i - x\|^2 + \|y_j - x\|^2) - 4d^2$$

- ▶ andererseits gibt es für alle $\varepsilon > 0$ ein $N_\varepsilon \in \mathbb{N}$ mit

$$\|y_k - x\|^2 \leq d^2 + \varepsilon \quad \forall k \geq N_\varepsilon$$

und somit

$$\|y_i - y_j\|^2 \leq 2(d^2 + \varepsilon + d^2 + \varepsilon) - 4d^2 = 4\varepsilon \quad \forall i, j \geq N_\varepsilon$$

- ▶ damit ist y_i eine Cauchy-Folge

- ▶ da V vollständig ist gibt es ein $y \in V$ mit $y_i \xrightarrow{i \rightarrow \infty} y$

- ▶ wegen $y_i \in X$, X abgeschlossen, ist dann auch $y \in X$

- Eindeutigkeit von y :

- ▶ für $y, \tilde{y} \in X$ gelte

$$d = \inf_{z \in X} \|z - x\| = \|y - x\| = \|\tilde{y} - x\|$$

- ▶ da X konvex ist gilt

$$\tilde{y} = \frac{y + \tilde{y}}{2} \in X$$

und mit der Parallelogrammgleichung folgt

$$\begin{aligned}
 \|\tilde{y} - x\|^2 &= \left\| \frac{y + \tilde{y}}{2} - x \right\|^2 \\
 &= \frac{1}{4} \left\| \underbrace{y - x}_u + \underbrace{\tilde{y} - x}_v \right\|^2 \\
 &= \frac{1}{4} \|u + v\|^2 \\
 &= \frac{1}{2} (\|u\|^2 + \|v\|^2) - \frac{1}{4} \|u - v\|^2 \\
 &= \frac{1}{2} (\|y - x\|^2 + \|\tilde{y} - x\|^2) - \frac{1}{4} \|y - \tilde{y}\|^2 \\
 &= d^2 - \frac{1}{4} \|y - \tilde{y}\|^2
 \end{aligned}$$

► für $y \neq \tilde{y}$ ist

$$\|\tilde{y} - x\|^2 < d^2$$

was ein Widerspruch zu $d = \inf_{z \in X} \|z - x\|$ ist

• Ungleichung:

► es sei $y \in X$ der eindeutige Minimierer und $d = \|y - x\| = \inf_{z \in X} \|z - x\|$:

■ da X konvex ist gilt für alle $z \in X$ und alle $\lambda \in (0, 1)$

$$(1 - \lambda)y + \lambda z = y + \lambda(z - y) \in X$$

■ damit folgt

$$\begin{aligned}
 \|y - x\|^2 = d^2 &\leq \|y + \lambda(z - y) - x\|^2 \\
 &= \|y - x\|^2 + \lambda^2 \|z - y\|^2 + 2\lambda(y - x, z - y)
 \end{aligned}$$

also

$$2\lambda(x - y, z - y) \leq \lambda^2 \|z - y\|^2$$

und wegen $\lambda > 0$

$$(x - y, z - y) \leq \frac{\lambda}{2} \|z - y\|^2$$

■ durch Grenzübergang $\lambda \downarrow 0$ erhalten wir schließlich

$$(x - y, z - y) \leq 0 \quad \forall z \in X$$

► es sei nun $y \in X$ mit $(x - y, z - y) \leq 0 \quad \forall z \in X$:

■ für $z \in X, z \neq y$, folgt dann

$$\begin{aligned}
 \|x - z\|^2 &= \|x - y + y - z\|^2 \\
 &= \|x - y\|^2 + \underbrace{\|y - z\|^2}_{>0} - \underbrace{2(x - y, z - y)}_{\geq 0} \\
 &> \|x - y\|^2
 \end{aligned}$$

■ somit ist y Minimierer von $\|x - z\|, z \in X$

□

Mit diesem Ergebnis machen die folgenden Definitionen Sinn.

Definition: Ist V ein Hilbert-Raum, $\emptyset \neq X \subset V$ konvex und abgeschlossen, dann ist

$$d_X : V \rightarrow \mathbb{R}, \quad d_X(x) = \inf_{z \in X} \|z - x\|$$

der *Abstand* von x zu X und

$$\Pi_X : V \rightarrow X, \quad \Pi_X(x) = \operatorname{argmin}_{z \in X} \|z - x\|$$

die *Projektion* von x auf X .

Bemerkung:

- wir lassen bei d, Π den Index X weg
- Π ist wohldefiniert, wenn V vollständig und die Norm auf V strikt konvex ist
- wird die Norm von einem Skalarprodukt induziert, dann ist sie immer strikt konvex
- ist dies nicht der Fall, kann man einfache Gegenbeispiele konstruieren

Beispiel:

- betrachte

$$V = \mathbb{R}^2, \quad \|x\|_\infty = \max(|x_1|, |x_2|),$$

- $(V, \|\cdot\|_\infty)$ ist ein Banachraum, also ein vollständiger normierter Vektorraum
- für die konvexe Menge

$$X = [-1, 1] \times [-1, 1]$$

und den Punkt $x = (2, 0)^T$ erhalten wir

$$d(x) = \inf_{z \in X} \|z - x\|_\infty = \inf_{z \in X} \max(|z_1 - 2|, |z_2|)$$

- wegen $z_1 \in [-1, 1]$ ist für alle $z \in X$

$$|z_1 - 2| \geq 1,$$

s.d. $d(x) \geq 1$

- andererseits gilt für alle z mit $z_1 = 1$ und $z_2 \in [-1, 1]$

$$\|z - x\|_\infty = \max(|z_1 - 2|, |z_2|) = 1,$$

der minimale Abstand $d(x) = 1$ wird also für alle diese z angenommen

- $d(x)$ ist also nach wie vor wohldefiniert, $\Pi(x)$ wegen der fehlenden Eindeutigkeit dagegen nicht

Jetzt betrachten wir einige wichtige Eigenschaften von d und Π .

Lemma: Sind V, X, d, Π wie oben definiert, dann gilt:

- $d : V \rightarrow \mathbb{R}$ ist konvex
- $(y - \Pi(y), x - \Pi(y)) \leq 0 \quad \forall x \in X, \forall y \in V$
- $\|\Pi(y) - \Pi(x)\| \leq \|y - x\| \quad \forall x, y \in V$
- $\|x - \Pi(y)\|^2 + \|y - \Pi(y)\|^2 \leq \|y - x\|^2 \quad \forall x \in X, \forall y \in V$

Beweis:

- Teil 1:

$$\triangleright x, y \in V, \bar{x} = \Pi(x), \bar{y} = \Pi(y)$$

- ▶ $\bar{x}, \bar{y} \in X$ und da X konvex ist gilt

$$\bar{z} = (1 - \lambda)\bar{x} + \lambda\bar{y} \in X \quad \forall \lambda \in [0, 1]$$

- ▶ mit $u = (1 - \lambda)x + \lambda y$ folgt

$$\begin{aligned} d((1 - \lambda)x + \lambda y) &= \inf_{z \in X} \|z - u\| \\ &\leq \|u - \bar{z}\| \\ &= \|(1 - \lambda)x + \lambda y - (1 - \lambda)\bar{x} - \lambda\bar{y}\| \\ &= \|(1 - \lambda)(x - \bar{x}) + \lambda(y - \bar{y})\| \\ &\leq (1 - \lambda)\|x - \bar{x}\| + \lambda\|y - \bar{y}\| \\ &= (1 - \lambda)d(x) + \lambda d(y) \end{aligned}$$

- Teil 2:

- ▶ nach dem Satz von oben gilt für $y \in V$

$$\bar{y} \in X, \quad \|y - \bar{y}\| = \inf_{x \in X} \|y - x\| \quad \Leftrightarrow \quad (y - \bar{y}, x - \bar{y}) \leq 0 \quad \forall x \in X$$

- ▶ mit $\bar{y} = \Pi(y)$ folgt die Behauptung

- Teil 3:

- ▶ es sei wieder $x, y \in V$, $\bar{x} = \Pi(x)$, $\bar{y} = \Pi(y)$

- ▶ nach Teil 2 gilt

$$(x - \bar{x}, z - \bar{x}) \leq 0, \quad (y - \bar{y}, z - \bar{y}) \leq 0 \quad \forall z \in X$$

- ▶ mit $z = \bar{y}$ folgt aus der ersten Ungleichung

$$(x - \bar{x}, \bar{y} - \bar{x}) \leq 0 \quad \Rightarrow \quad (\bar{x} - x, \bar{x} - \bar{y}) \leq 0$$

und analog mit $z = \bar{x}$ in der zweiten Ungleichung

$$(y - \bar{y}, \bar{x} - \bar{y}) \leq 0$$

- ▶ Addition der beiden Ungleichungen liefert

$$(\bar{x} - x + y - \bar{y}, \bar{x} - \bar{y}) \leq 0$$

also

$$-(x - y, \bar{x} - \bar{y}) + \|\bar{x} - \bar{y}\|^2 \leq 0$$

- ▶ mit Cauchy-Schwarz folgt

$$\|\bar{x} - \bar{y}\|^2 \leq (x - y, \bar{x} - \bar{y}) \leq \|x - y\| \|\bar{x} - \bar{y}\|$$

und somit

$$\|\bar{x} - \bar{y}\| \leq \|x - y\|$$

- Teil 4:

- ▶ $\forall v, w \in V$ gilt

$$\|v - w\|^2 = (v - w, v - w) = \|v\|^2 + \|w\|^2 - 2(v, w)$$

also

$$\|v\|^2 + \|w\|^2 - \|v - w\|^2 = 2(v, w)$$

- ▶ mit $v = x - \bar{y}$, $w = y - \bar{y}$ folgt

$$\|x - \bar{y}\|^2 + \|y - \bar{y}\|^2 - \|x - y\|^2 = 2(x - \bar{y}, y - \bar{y}) \leq 0$$

□

1.3 Konvergenz

Wir werden jetzt analog zum einfachen Gradientenverfahren Konvergenzaussagen unter verschiedenen Voraussetzungen an f beweisen. Dabei werden wir sehen, dass die asymptotischen Aussagen sich nicht verändern, d.h. die Projektion auf abgeschlossene konvexe Mengen hat keinen negativen Einfluss.

1.3.1 Vorüberlegungen

Für $f \in C^1(\mathbb{R}^d)$, $X \subset \mathbb{R}^d$ konvex und abgeschlossen, wenden wir auf das restringierte Optimierungsproblem

$$x_* = \operatorname{argmin}_{x \in X} f(x)$$

Projected-Gradient-Descent

$$y_{t+1} = x_t - \gamma f'(x_t), \quad x_{t+1} = \Pi(y_{t+1})$$

mit konstanter Schrittweite γ an, wobei Π die Projektion in \mathbb{R}^d auf X bezüglich $(\cdot, \cdot)_2$ ist. Wegen $y_{t+1} = x_t - \gamma f'_t$ gilt

$$\|y_{t+1} - x_*\|_2^2 = \|x_t - x_*\|_2^2 + \gamma^2 \|f'_t\|_2^2 - 2\gamma f'_t(x_t - x_*)$$

und somit

$$f'_t(x_t - x_*) = \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|y_{t+1} - x_*\|_2^2 \right).$$

Der einzige Unterschied zu Gradient-Descent ist y_{t+1} statt x_{t+1} im letzten Term auf der rechten Seite.

Um diesen Term zu bearbeiten, greifen wir auf die Eigenschaften der Projektion Π zurück. Für Π gilt

$$\|\Pi(y) - \Pi(x)\| \leq \|y - x\| \quad \forall x, y \in V$$

bzw.

$$\Pi(x_*) = x_*$$

und somit

$$\|x_{t+1} - x_*\|_2 = \|\Pi(y_{t+1}) - \Pi(x_*)\|_2 \leq \|y_{t+1} - x_*\|_2,$$

bzw.

$$f'_t(x_t - x_*) \leq \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2 \right).$$

Wir erhalten also fast das selbe Ergebnis wie bei Gradient-Descent, nur dass jetzt das “=” durch “≤” ersetzt wurde.

Ist f konvex, dann gilt

$$f(y) \geq f(x) + f'(x)(y - x)$$

und mit $y = x_*$, $x = x_t$

$$f_* \geq f_t + f'_t(x_* - x_t)$$

bzw.

$$\begin{aligned} 0 &\leq f_t - f_* \leq f'_t(x_t - x_*) \\ &= \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|y_{t+1} - x_*\|_2^2 \right) \\ &\leq \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2 \right). \end{aligned}$$

1.3.2 Lipschitz-Stetigkeit

$f \in C^1(\mathbb{R}^d)$ sei konvex und zusätzlich Lipschitz-Stetigkeit mit Konstante L_f , also

$$\|f(y) - f(x)\| \leq L_f \|y - x\|$$

was äquivalent ist zu

$$\|f'(x)\| \leq L_f.$$

Wie bei Gradient-Descent folgt

$$\begin{aligned}
 \sum_{t=0}^{T-1} (f_t - f_*) &\leq \sum_{t=0}^{T-1} f'_t(x_t - x_*) \\
 &\leq \frac{\gamma}{2} T L_f^2 + \frac{1}{2\gamma} \left(\underbrace{\|x_0 - x_*\|_2^2}_{e_0^2} - \underbrace{\|x_T - x_*\|_2^2}_{\geq 0} \right) \\
 &\leq \frac{\gamma T L_f^2}{2} + \frac{e_0^2}{2\gamma}.
 \end{aligned}$$

Satz: $f : \mathbb{R}^d \rightarrow \mathbb{R}$, konvex, C^1 , L -stetig mit Konstante L_f und es existiere $x_* = \operatorname{argmin}_{x \in \mathbb{R}^d} f(x)$. Mit $\gamma = \frac{c}{T^\omega}$, $\omega \in (0, 1)$, gilt

$$\begin{aligned}
 \min_{t=0, \dots, T-1} (f_t - f_*) &\leq \frac{1}{T} \sum_{t=0}^{T-1} (f_t - f_*) \\
 &= \mathcal{O}\left(\left(\frac{1}{T}\right)^{\min(\omega, 1-\omega)}\right) \quad \text{für } T \rightarrow \infty.
 \end{aligned}$$

Die optimale Ordnung ist $\frac{1}{2}$ für $\omega = \frac{1}{2}$. Mit $e_0 = \|x_0 - x_*\|$, $\gamma = \frac{e_0}{L_f \sqrt{T}}$ gilt außerdem

$$\min_{t=0, \dots, T-1} (f_t - f_*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f_t - f_*) \leq \frac{L_f e_0}{\sqrt{T}}.$$

1.3.3 L -Glattheit

Wir leiten zuerst eine neue Version des Descent-Lemmas her. Dazu starten wir mit der L -Glattheit von f

$$f_{t+1} \leq f_t + f'_t(x_{t+1} - x_t) + \frac{L}{2} \|x_{t+1} - x_t\|_2^2$$

benutzen

$$y_{t+1} = x_t - \gamma f'_t$$

bzw.

$$f'_t = \frac{1}{\gamma} (x_t - y_{t+1})$$

und erhalten

$$f_{t+1} \leq f_t - \frac{1}{\gamma} \underbrace{(y_{t+1} - x_t)^T}_{u} \underbrace{(x_{t+1} - x_t)}_v + \frac{L}{2} \|x_{t+1} - x_t\|_2^2.$$

Wegen $2u^T v = 2(u, v)_2 = \|u\|_2^2 + \|v\|_2^2 - \|u - v\|_2^2$ folgt

$$\begin{aligned}
 f_{t+1} &\leq f_t - \frac{1}{2\gamma} (\|y_{t+1} - x_t\|_2^2 + \|x_{t+1} - x_t\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2) + \frac{L}{2} \|x_{t+1} - x_t\|_2^2 \\
 &= f_t - \frac{1}{2\gamma} (\gamma^2 \|f'_t\|_2^2 + \|x_{t+1} - x_t\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2) + \frac{L}{2} \|x_{t+1} - x_t\|_2^2 \\
 &= f_t - \frac{\gamma}{2} \|f'_t\|_2^2 + \frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2 + \frac{1}{2} \left(L - \frac{1}{\gamma}\right) \|x_{t+1} - x_t\|_2^2.
 \end{aligned}$$

Für $0 < \gamma \leq \frac{1}{L}$ ist $L - \frac{1}{\gamma} \leq 0$ und wir erhalten das folgende Ergebnis.

Descent-Lemma: Ist $f : \mathbb{R}^d \rightarrow \mathbb{R}$ L -glatt und $0 < \gamma \leq \frac{1}{L}$, dann gilt für Projected-Gradient-Descent

$$f_{t+1} \leq f_t - \frac{\gamma}{2} \|f'_t\|_2^2 + \frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2.$$

Bemerkung:

- bei Gradient-Descent war

$$f_{t+1} \leq f_t - \beta \|f'_t\|_2^2, \quad \beta = \gamma \left(1 - \frac{\gamma L}{2}\right),$$

so dass die f_t bei $0 < \gamma < 2/L$ monoton fallend waren

- bei Projected-Gradient-Descent haben wir auf der rechten Seite den nicht-negativen Zusatzterm

$$\frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2,$$

so dass wir zunächst nichts über die Monotonie der f_t aussagen können

- man kann aber trotzdem zeigen, dass die f_t auch hier (wenn γ kurz genug ist) monoton fallen (Übung)

Aus den Vorüberlegungen wissen wir (f konvex)

$$\begin{aligned} 0 &\leq f_t - f_* \leq f'_t(x_t - x_*) \\ &= \frac{1}{2\gamma} (\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|y_{t+1} - x_*\|_2^2). \end{aligned}$$

Laut Descent-Lemma ist

$$\|f'_t\|_2^2 \leq \frac{2}{\gamma} (f_t - f_{t+1} + \frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2)$$

und oben eingesetzt folgt

$$f_t - f_* \leq f_t - f_{t+1} + \frac{1}{2\gamma} (\|y_{t+1} - x_{t+1}\|_2^2 + \|x_t - x_*\|_2^2 - \|y_{t+1} - x_*\|_2^2).$$

Wegen der Eigenschaft

$$\|x - \Pi(y)\|^2 + \|y - \Pi(y)\|^2 \leq \|y - x\|^2 \quad \forall x \in X, \forall y \in V$$

der Projektion Π und $x_* \in X$ folgt mit $y = y_{t+1}$, $x = x_*$

$$\begin{aligned} \|y_{t+1} - x_{t+1}\|_2^2 &= \|y_{t+1} - \Pi(y_{t+1})\|_2^2 \\ &\leq \|y_{t+1} - x_*\|_2^2 - \|x_* - \Pi(y_{t+1})\|_2^2 \\ &= \|y_{t+1} - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2 \end{aligned}$$

so dass

$$f_t - f_* \leq f_t - f_{t+1} + \frac{1}{2\gamma} (\|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2).$$

Durch Summation erhalten wir

$$\sum_{t=0}^{T-1} (f_t - f_*) \leq f_0 - f_T + \frac{1}{2\gamma} (\|x_0 - x_*\|_2^2 - \|x_T - x_*\|_2^2).$$

Benutzen wir jetzt noch

$$f_0 - f_T = (f_0 - f_*) - (f_T - f_*), \quad \|x_T - x_*\|_2^2 \geq 0,$$

dann ist

$$\sum_{t=1}^T (f_t - f_*) \leq \frac{1}{2\gamma} \|x_0 - x_*\|_2^2.$$

Nach dem Descent-Lemma und der daran anschließenden Bemerkung gilt $f_{t+1} \leq f_t$ und somit

$$f_T - f_* \leq \frac{1}{T} \sum_{t=1}^T (f_t - f_*) \leq \frac{1}{2\gamma T} \|x_0 - x_*\|_2^2.$$

Satz: $f : \mathbb{R}^d \rightarrow \mathbb{R}$, konvex, L -glatt mit Konstante L und es existiere $x_* = \operatorname{argmin}_{x \in X} f(x)$. Ist $0 < \gamma \leq \frac{1}{L}$ dann gilt für Projected-Gradient-Descent

$$f_T - f_* \leq \frac{1}{2\gamma T} \|x_0 - x_*\|_2^2 = \mathcal{O}\left(\frac{1}{T}\right) \quad \text{für } T \rightarrow \infty.$$

1.3.4 μ -Konvexität

Ist f μ -konvex mit $\mu \geq 0$, dann gilt

$$f_* \geq f_t + f'_t(x_* - x_t) + \frac{\mu}{2} \|x_* - x_t\|_2^2$$

bzw.

$$f_t - f_* \leq f'_t(x_t - x_*) - \frac{\mu}{2} \|x_t - x_*\|_2^2.$$

Aus den Vorüberlegungen wissen wir

$$f'_t(x_t - x_*) = \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|y_{t+1} - x_*\|_2^2 \right).$$

Wegen

$$\|x - \Pi(y)\|^2 + \|y - \Pi(y)\|^2 \leq \|x - y\|^2 \quad \forall x \in X \quad \forall y \in V$$

folgt mit $y = y_{t+1}$, $x = x_*$, $\Pi(y_{t+1}) = x_{t+1}$

$$\|x_* - x_{t+1}\|_2^2 + \|y_{t+1} - x_{t+1}\|_2^2 \leq \|x_* - y_{t+1}\|_2^2,$$

also

$$-\|y_{t+1} - x_*\|_2^2 \leq -\|x_{t+1} - x_*\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2.$$

Oben eingesetzt erhalten wir nun

$$\begin{aligned} f_t - f_* &\leq f'_t(x_t - x_*) - \frac{\mu}{2} \|x_t - x_*\|_2^2 \\ &\leq \frac{1}{2\gamma} \left(\gamma^2 \|f'_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2 \right) \\ &\quad - \frac{\mu}{2} \|x_t - x_*\|_2^2, \end{aligned}$$

also

$$\begin{aligned} 2\gamma(f_t - f_*) &\leq \gamma^2 \|f'_t\|_2^2 + (1 - \gamma\mu) \|x_t - x_*\|_2^2 \\ &\quad - \|x_{t+1} - x_*\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2 \end{aligned}$$

bzw.

$$\begin{aligned} \|x_{t+1} - x_*\|_2^2 &\leq 2\gamma(f_* - f_t) + \gamma^2 \|f'_t\|_2^2 - \|y_{t+1} - x_{t+1}\|_2^2 \\ &\quad + (1 - \gamma\mu) \|x_t - x_*\|_2^2. \end{aligned}$$

Die ersten drei Terme auf der rechten Seite schätzen wir wieder mit dem Descent-Lemma ab. Wegen

$$f_{t+1} \leq f_t - \frac{\gamma}{2} \|f'_t\|_2^2 + \frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2$$

ist

$$f_* - f_t \leq f_{t+1} - f_t \leq -\frac{\gamma}{2} \|f'_t\|_2^2 + \frac{1}{2\gamma} \|y_{t+1} - x_{t+1}\|_2^2$$

und somit

$$\|x_{t+1} - x_*\|_2^2 \leq (1 - \gamma\mu) \|x_t - x_*\|_2^2.$$

Analog zu Gradient-Descent haben wir damit folgendes Ergebnis gezeigt.

Satz: $f : \mathbb{R}^d \rightarrow \mathbb{R}$, μ -konvex mit $\mu > 0$, L -glatt mit Konstante L und es existiere $x_* = \operatorname{argmin}_{x \in X} f(x)$. Für $0 < \gamma \leq \frac{1}{L}$ folgt

$$\|x_{t+1} - x_*\|_2^2 \leq \rho \|x_t - x_*\|_2^2$$

und

$$f_T - f_* \leq \frac{L}{2} \rho^T \|x_0 - x_*\|_2^2$$

mit

$$\rho = 1 - \gamma\mu \in [0, 1).$$

1.4 Projektionsoperatoren

In den vorherigen Abschnitten haben wir gesehen, dass wir für Projected-Gradient-Descent exakt die selben asymptotischen Resultate erhalten wie bei gewöhnlichem Gradient-Descent. Das sieht zunächst sehr angenehm aus, für den praktischen Einsatz muss man allerdings bedenken, dass in jedem Schritt eine Projektion

$$x_{t+1} = \Pi_X(y_{t+1}), \quad \Pi_X(x) = \operatorname{argmin}_{z \in X} \|z - x\|$$

auf die abgeschlossene, konvexe Menge X zu berechnen ist.

Das Berechnen von $\Pi(x)$ ist also selbst ein restringiertes konvexes Optimierungsproblem mit einer “einfachen” konvexen Zielfunktion $x \rightarrow \|z - x\|$. Für allgemeine abgeschlossene und konvexe Menge X kann die Lösung dieses Problems extrem schwierig werden, für spezielle X , die in der Praxis häufig auftauchen, kann man Π_X dagegen explizit angeben.

Wir untersuchen einige $X \subset \mathbb{R}^d$ nun genauer. Dabei betrachten wir jeweils Projektionen bezüglich des euklidischen Skalarprodukts $(\cdot, \cdot)_2$.

1.4.1 Kugel in der 2-Norm

- wir betrachten

$$X = \bar{B}_r(0)_{\|\cdot\|_2} = \{x \mid x \in \mathbb{R}^d, \|x\|_2 \leq r\}$$

- X ist offensichtlich konvex und abgeschlossen
- die Projektion auf X ist

$$\Pi_X(x) = \begin{cases} x & \|x\|_2 \leq r \\ \frac{x}{\|x\|_2} r & \|x\|_2 > r \end{cases}$$

- mit $\bar{x} = \Pi_X(x)$ ist zu zeigen, dass

$$(x - \bar{x}, z - \bar{x})_2 \leq 0 \quad \forall z \in X$$

- für $x \in X$ ist $\bar{x} = x$, also

$$(x - \bar{x}, z - \bar{x})_2 = (x - x, z - x)_2 = 0 \quad \forall z \in X$$

- für $x \notin X$, also $\|x\|_2 > r$, ist $\bar{x} = \frac{x}{\|x\|_2} r$ und somit

$$\begin{aligned} (x - \bar{x}, z - \bar{x})_2 &= \left(x - \frac{x}{\|x\|_2} r, z - \frac{x}{\|x\|_2} r\right)_2 \\ &= (x, z)_2 + r^2 - \left(x, \frac{x}{\|x\|_2} r\right)_2 - \left(\frac{x}{\|x\|_2} r, z\right)_2 \\ &= (x, z)_2 + r^2 - \|x\|_2 r - \frac{r}{\|x\|_2} (x, z)_2 \\ &= \underbrace{\left(1 - \frac{r}{\|x\|_2}\right)}_{>0} (x, z)_2 + r^2 - r\|x\|_2 \\ &\leq \left(1 - \frac{r}{\|x\|_2}\right) \|x\|_2 \underbrace{\|z\|_2}_{\leq r} + r^2 - r\|x\|_2 \\ &\leq r\|x\|_2 - r^2 + r^2 - r\|x\|_2 \\ &= 0 \end{aligned}$$

1.4.2 Nicht negativer Kegel

- der Kegel

$$X = \{x \mid x \in \mathbb{R}^d, x_i \geq 0, i = 1, \dots, d\}$$

ist konvex und abgeschlossen

- die Projektion auf X ist definiert durch

$$\bar{x} = \Pi_X(x), \quad \bar{x}_i = \begin{cases} x_i & x_i \geq 0 \\ 0 & x_i < 0 \end{cases}$$

- für $z \in X$ folgt dann

$$\begin{aligned} (x - \bar{x}, z - \bar{x})_2 &= \sum_{i=1}^d (x_i - \bar{x}_i)(z_i - \bar{x}_i) \\ &= \sum_{\substack{x_i < 0 \\ < 0}} \underbrace{x_i}_{< 0} \underbrace{z_i}_{\geq 0} \\ &\leq 0 \end{aligned}$$

1.4.3 Kugel in der 1-Norm

- wir betrachten

$$X_r = B_r(0)_{\|\cdot\|_1} = \left\{ x \mid x \in \mathbb{R}^d, \|x\|_1 = \sum_{i=1}^d |x_i| \leq r \right\}$$

- X_r ist damit konvex und abgeschlossen und die Projektion Π auf X_r bezüglich der Norm $\|\cdot\|_2$ ist wohldefiniert:

$$\Pi(v) = \operatorname{argmin}_{\|y\|_1 \leq r} \|v - y\|_2$$

- wegen $\Pi(v) = v$ für $\|v\|_1 \leq r$ reicht es, wenn wir ab jetzt Vektoren

$$v \in \mathbb{R}^d, \quad \|v\|_1 > r$$

betrachten

- für diese gilt $\|\Pi(v)\|_1 = r$, d.h. die Projektion liegt auf dem Rand von X_r :

- ▶ Annahme: $\|\Pi(v)\|_1 < r$
- ▶ wegen $\|v\|_1 > r > \|\Pi(v)\|_1$ gilt

$$\lambda = \frac{r - \|\Pi(v)\|_1}{\|v\|_1 - \|\Pi(v)\|_1} \in (0, 1)$$

- ▶ für

$$x = (1 - \lambda)\Pi(v) + \lambda v$$

erhalten wir

$$\begin{aligned} \|x\|_1 &\leq (1 - \lambda)\|\Pi(v)\|_1 + \lambda\|v\|_1 \\ &= \|\Pi(v)\|_1 + \lambda(\|v\|_1 - \|\Pi(v)\|_1) \\ &= \|\Pi(v)\|_1 + \frac{r - \|\Pi(v)\|_1}{\|v\|_1 - \|\Pi(v)\|_1}(\|v\|_1 - \|\Pi(v)\|_1) \\ &= r \end{aligned}$$

- ▶ andererseits gilt

$$x - v = (1 - \lambda)(\Pi(v) - v), \quad \lambda \in (0, 1)$$

und somit

$$\|x - v\|_2 = (1 - \lambda)\|\Pi(v) - v\|_2 < \|\Pi(v) - v\|_2,$$

was ein Widerspruch zu

$$\Pi(v) = \operatorname{argmin}_{\|y\|_1 \leq r} \|v - y\|_2$$

ist

- wir werden jetzt die Menge der zu betrachtenden Vektoren v weiter einschränken
- ist $L : \mathbb{R}^d \rightarrow \mathbb{R}^d$ eine lineare Abbildung mit

$$\|Lw\|_1 = \|w\|_1, \quad \|Lw\|_2 = \|w\|_2 \quad \forall w \in \mathbb{R}^d$$

dann ist L umkehrbar und es gilt für $x = \Pi(w)$

$$Lx = \Pi(Lw)$$

bzw.

$$x = L^{-1}\Pi(Lw)$$

denn

$$\begin{aligned} \|Lw - Lx\|_2 &= \|L(w - x)\|_2 \\ &= \|w - x\|_2 \\ &= \min_{\|y\|_1 \leq r} \|w - y\|_2 \\ &= \min_{\|y\|_1 \leq r} \|Lw - Ly\|_2 \\ &= \min_{\|L^{-1}z\|_1 \leq r} \|Lw - z\|_2 \\ &= \min_{\|z\|_1 \leq r} \|Lw - z\|_2 \end{aligned}$$

- die Abbildung

$$Sw = (s_1 w_1, \dots, s_d w_d)^T, \quad s_i = \pm 1$$

besitzt diese Eigenschaften:

- ▶ für $v \in \mathbb{R}^d$,

$$s_i = \begin{cases} 1 & v_i \geq 0 \\ -1 & v_i < 0 \end{cases},$$

folgt dann $Sv = (|v_1|, \dots, |v_d|)^T = |v|$ (komponentenweise) und

$$x = \Pi(v) = S^{-1}\Pi(Sv) = S^{-1}\Pi(|v|),$$

so dass es genügt, die Projektion für Vektoren v mit $v_i \geq 0$ zu betrachten

- die Abbildung

$$Pw = (w_{\pi(1)}, \dots, w_{\pi(d)})^T$$

wobei π eine beliebige Permutation der Indizes $1, \dots, d$ ist, besitzt ebenfalls die oben beschriebenen Eigenschaften:

- ▶ für $v \in \mathbb{R}^d$ betrachten wir jetzt eine Permutation π , die die Komponenten von v absteigend sortiert, also

$$v_{\pi(1)} \geq v_{\pi(2)} \geq \dots \geq v_{\pi(d)}$$

und erhalten

$$x = \Pi(v) = P^{-1}\Pi(Pv),$$

so dass es genügt, die Projektion für Vektoren v zu betrachten, deren Komponenten absteigend sortiert sind

- wir müssen jetzt also nur noch Vektoren $v \in \mathbb{R}^d$ betrachten mit

$$\|v\|_1 > r, \quad v_1 \geq v_2 \geq \dots \geq v_d \geq 0$$

und wissen bereits, dass

$$\|\Pi(v)\|_1 = r$$

ist

- unter diesen Voraussetzungen gilt für $x = \Pi(v)$ auch $x_i \geq 0$:

► Annahme: es existiere ein $x_k < 0$

► mit

$$y = (x_1, \dots, x_{k-1}, -x_k, x_{k+1}, \dots, x_d)^T$$

ist $\|y\|_1 = \|x\|_1 = r$ und wegen $x_k < 0 \leq v_k$

$$\begin{aligned} \|v - y\|_2^2 &= \sum_{i=1}^d (v_i - y_i)^2 \\ &= (v_k + x_k)^2 + \sum_{i \neq k} (v_i - x_i)^2 \\ &< (v_k - x_k)^2 + \sum_{i \neq k} (v_i - x_i)^2 \\ &= \|v - x\|_2^2 \end{aligned}$$

was ein Widerspruch zu $x = \Pi(v)$ ist

- somit folgt unter diesen Voraussetzungen an v

$$\Pi(v) = \operatorname{argmin}_{x \in Y_r} \|v - x\|_2,$$

$$Y_r = \left\{ x \mid x \in \mathbb{R}^d, x_i \geq 0, i = 1, \dots, d, \sum_{i=1}^d x_i = r \right\},$$

wobei Y_r wieder konvex ist

- wir zeigen jetzt, dass ein eindeutiger Index $p \in \{1, \dots, d\}$ existieren muss mit $x_i > 0$ für $i \leq p$ und $x_i = 0$ für $i > p$:
 - $x = \Pi(v)$ minimiert die konvexe differenzierbare Funktion $f(y) = \frac{1}{2} \|y - v\|_2^2$ über der konvexen Menge Y_r , weshalb

$$0 \leq f'(x)(y - x) = (x - v)^T (y - x) \quad \forall y \in Y_r$$

gelten muss, also

$$0 \leq \sum_{i=1}^d (x_i - v_i)(y_i - x_i) \quad \forall y \in Y_r$$

- nach oben wissen wir, dass $\|x\|_1 = r > 0$, $x_i \geq 0$, $i = 1, \dots, d$, ist, d.h. es existiert ein Index k mit $x_k > 0$
- nehmen wir nun an, dass ein Index j existiert mit $x_j = 0$ und $x_{j+1} > 0$
- definieren wir für $\varepsilon > 0$

$$y = (x_1, \dots, x_{j-1}, \varepsilon, x_{j+1} - \varepsilon, x_{j+2}, \dots, x_d)^T$$

dann ist $y_i \geq 0$, $i = 1, \dots, d$, $\|y\|_1 = \|x\|_1 = r$, also $y \in Y_r$, und

$$\begin{aligned} \sum_{i=1}^d (x_i - v_i)(y_i - x_i) &= (x_j - v_j)(y_j - x_j) + (x_{j+1} - v_{j+1})(y_{j+1} - x_{j+1}) \\ &= -v_j \varepsilon - (x_{j+1} - v_{j+1}) \varepsilon \\ &= \varepsilon \underbrace{(v_{j+1} - v_j)}_{\leq 0} - \underbrace{x_{j+1}}_{> 0} \\ &< 0 \end{aligned}$$

was ein Widerspruch zu

$$0 \leq \sum_{i=1}^d (x_i - v_i)(y_i - x_i) \quad \forall y \in Y_r$$

ist

- ▶ damit kann der Fall $x_j = 0, x_{j+1} > 0$ nicht auftreten
- ▶ wegen $\|x\|_1 = r > 0$ muss $x \neq 0$ sein, weshalb es einen Index p gibt mit $x_i > 0$ für $i \leq p$ und $x_i = 0$ für $i > p$
- für $x = x(p) = \Pi(v)$ gilt

$$x_i = \begin{cases} v_i - c_p > 0 & i = 1, \dots, p \\ 0 & i = p+1, \dots, d' \end{cases}$$

$$c_p = \frac{1}{p} \left(\sum_{i=1}^p v_i - r \right)$$

- ▶ Annahme: es existiere ein Index $j < p$ mit $x_j - v_j \neq x_{j+1} - v_{j+1}$
 - ohne Einschränkung können wir $x_j - v_j < x_{j+1} - v_{j+1}$ annehmen
 - wegen $j < p$ ist $x_j > 0$, so dass für $0 < \varepsilon \leq x_j$

$$y = (x_1, \dots, x_{j-1}, x_j - \varepsilon, x_{j+1} + \varepsilon, x_{j+2}, \dots, x_d)^T \in Y_r$$

- analog zum letzten Abschnitt erhalten wir

$$\begin{aligned} (x - v)^T (y - x) &= (x_j - v_j)(y_j - x_j) + (x_{j+1} - v_{j+1})(y_{j+1} - x_{j+1}) \\ &= (x_j - v_j)\varepsilon - (x_{j+1} - v_{j+1})\varepsilon \\ &< 0 \end{aligned}$$

was erneut ein Widerspruch zu

$$0 \leq (x - v)^T (y - x) \quad \forall y \in Y_r$$

ist

- ▶ damit ist also

$$x_i = \begin{cases} v_i - c_p > 0 & i = 1, \dots, p \\ 0 & i = p+1, \dots, d \end{cases}$$

- ▶ wegen $x \in Y_r$ gilt

$$\begin{aligned} r = \|x\|_1 &= \sum_{i=1}^d |x_i| = \sum_{i=1}^p x_i \\ &= \sum_{i=1}^p (v_i - c_p) \\ &= \left(\sum_{i=1}^p v_i \right) - pc_p \end{aligned}$$

und somit

$$c_p = \frac{1}{p} \left(\sum_{i=1}^p v_i - r \right)$$

- zum Schluss muss jetzt noch der Index p bestimmt werden
- es gilt $\Pi(v) = x(p_*)$ für

$$p_* = \operatorname{argmax}_{p \in \{1, \dots, d\}} \{v_p - c_p > 0\}$$

- ▶ für jedes $p \in \{1, \dots, d\}$ ist

$$x_i = \begin{cases} v_i - c_p > 0 & i = 1, \dots, p \\ 0 & i = p+1, \dots, d' \end{cases}$$

$$c_p = \frac{1}{p} \left(\sum_{i=1}^p v_i - r \right)$$

eindeutige Lösung von

$$\operatorname{argmin}_{z \in Z_p} \|z - v\|_2^2$$

mit

$$Z_p = \left\{ z \mid z \in \mathbb{R}^d, z_i \geq 0, z_i = 0 \ \forall i > p, \|z\|_1 = \sum_{i=1}^p z_i = r \right\} \subset Y_r,$$

denn Z_p ist abgeschlossen und konvex, $f(z) = \|z - v\|_2^2$ ist konvex und für alle $z \in Z_p$ gilt

$$\begin{aligned} f'(x)(z - x) &= (x - v)^T (z - x) \\ &= \sum_{i=1}^p (x_i - v_i)(z_i - x_i) \\ &= -c_p \sum_{i=1}^p (z_i - x_i) \\ &= 0 \end{aligned}$$

► Annahme: $p < p_*$

■ dann ist

$$\begin{aligned} Z_p \ni x(p) = \Pi(v) &= \operatorname{argmin}_{y \in Y_r} \|y - v\|_2^2 \\ &= \operatorname{argmin}_{z \in Z_p} \|z - v\|_2^2 \end{aligned}$$

bzw.

$$Z_{p_*} \ni x(p_*) = \operatorname{argmin}_{z \in Z_{p_*}} \|z - v\|_2^2$$

- nach Definition ist $Z_p \subset Z_{p_*} \subset Y_r$ und alle Mengen sind konvex und abgeschlossen, so dass alle Minima eindeutig sind
- somit ist $x(p) = x(p_*)$
- nach Konstruktion von $x(p), x(p_*)$ gilt wegen $p < p_*$

$$x(p)_{p+1} = 0, \quad x(p_*)_{p+1} \neq 0,$$

was zu einem Widerspruch führt

- zusammengefasst erhalten wir damit folgenden Algorithmus zur Berechnung von $x = \Pi(v)$:

- $v \in \mathbb{R}^d$ gegeben
- ist $\|v\|_1 \leq r$ dann ist $x = v$
- $\|v\|_1 > r$:
 - setze

$$w = PSv,$$

d.h. w enthält die Beträge der Komponenten von v absteigend sortiert

- bestimme

$$p_* = \operatorname{argmax}_{p \in \{1, \dots, d\}} \left\{ w_p - \frac{1}{p} \left(\sum_{i=1}^p w_i - r \right) > 0 \right\}$$

- berechne y als

$$y_i = \begin{cases} w_i - c_{p_*} > 0 & i = 1, \dots, p_* \\ 0 & i = p_* + 1, \dots, d' \end{cases}$$

$$c_{p_*} = \frac{1}{p_*} \left(\sum_{i=1}^{p_*} w_i - r \right)$$

- damit folgt

$$x = S^{-1}P^{-1}y$$

- eine Anwendung in \mathbb{R}^2 bzw. \mathbb{R}^3 liefert folgende Resultate

```
%matplotlib inline

import numpy as np
import matplotlib.pyplot as plt

def l1pro(v, r = 1.0):
    # Projektion auf L1-Kugel mit Radius r bzgl. eukl. Skalarpr.

    if np.linalg.norm(v, ord=1) > r:
        d = v.shape[0]

        # S, Vorzeichen merken fuer S_inv
        s = np.ones(v.shape)
        s[v < 0] = -1

        # PS anwenden
        w = s * v
        ii = w.argsort()[::-1]
        w = w[ii]

        # Projektion
        p = np.arange(d) + 1
        cp = (w.cumsum() - r) / p
        u = w - cp
        jj = np.where(u > 0)[0].max()

        ps = p[jj]
        cps = cp[jj]

        y = np.zeros(v.shape)
        y[:ps] = w[:ps] - cps

        # P_inv und S_inv anwenden
        x = np.zeros(y.shape)
        # P_inv
        x[ii] = y
        # S_inv = S
        x = s*x
    else:
        x = v

    return x

np.random.seed(17)
plt.figure(figsize=(5,5))


d = 2
n = 500
l = 1.0
r = 2.0

for k in range(n):
    w = np.random.randn(d)
    w = w/np.linalg.norm(w) * (l+r)

    x = l1pro(w, r)

    plt.plot(*w, 'b.', markersize = 1)
    plt.plot(*np.c_[x, w], 'b', alpha = 0.05)
    plt.plot(*x, 'r.', markersize = 1)

plt.axis('equal')
plt.gca().set_xticks([])
plt.gca().set_yticks([]);
```

```

%%matplotlib notebook
%matplotlib inline

plt.figure(figsize=(8,8))
plt.axes(projection='3d')
ax = plt.gca()

np.random.seed(17)

d = 3
n = 1000
l = 1.0
r = 2.0

for k in range(n):
    w = np.random.randn(d)
    w = w/np.linalg.norm(w)*(l + r)


    x = l1pro(w, r)

    ax.plot(*w, 'b.', markersize = 1)
    ax.plot(*np.c_[x, w], 'b', alpha = 0.05)
    ax.plot(*x, 'r.', markersize = 1)

#plt.axis('equal')
lr = l + r

ax.set_xlim(-lr, lr)
ax.set_ylim(-lr, lr)
ax.set_zlim(-lr, lr)
ax.set_xticks([])
ax.set_yticks([])
ax.set_zticks([]);

```



1.5 Beispiel Tomographie

Bei den Regularisierungsverfahren hatten wir für unser Tomographieproblem unter anderem die Lasso-Methode kennen gelernt. Dort bestimmt man

$$\operatorname{argmin}_{w \in \mathbb{R}^n} \frac{1}{2m} \|Xw - y\|_2^2 + \alpha \|w\|_1,$$

wobei $\alpha > 0$ ein vom Benutzer zu wählender Regularisierungsparameter ist.

Dieses nicht restringierte Problem kann in das restringierte Problem

$$\operatorname{argmin}_{\|w\|_1 \leq r} \frac{1}{2m} \|Xw - y\|_2^2$$

überführt werden, wobei die Rolle des Regularisierungsparameters α jetzt von r übernommen wird:

- für $r \rightarrow \infty$ ist $\|w\|_1 \leq r$ immer weniger einschränkend, man “regularisiert” immer weniger, was $\alpha \rightarrow 0$ entspricht
- für $r \rightarrow 0$ bleibt nur $w = 0$ als Lösung, d.h. man “regularisiert” maximal, was $\alpha \rightarrow \infty$ entspricht

Auf das restringierte Problem wenden wir Projected-Gradient-Descent an und benutzen dabei die Projektion auf $B_r(0)_{\|\cdot\|_1}$ aus dem letzten Abschnitt.

Zum Vergleich berechnen wir zunächst eine Rekonstruktion ohne Regularisierung.

```
%matplotlib inline
np.random.seed(17)


from DatenNotebooks.xrtomol2 import *

def plotReko(b):
    n = int(np.sqrt(b.shape[0]))
    plt.pcolor(b.reshape(n,n))
    plt.axis('equal')
    plt.axis('off')

from sklearn import linear_model
X, y, _ = tomo(delta = 0.01)

modell = linear_model.LinearRegression(fit_intercept = False)
modell.fit(X, y.ravel())
```


```
w = modell.coef_  
plotReko(w)
```



Die Lasso-Implementierung aus Scikit-Learn liefert das folgende Ergebnis.

```
lassocv = linear_model.LassoCV(fit_intercept = False, cv = 5)  
  
lassocv.fit(X, y)  
  
w = lassoconv.coef_  
plotReko(w)  
  
print('alpha = {:e},    ||w||_1 = {:f}'.format(lassocv.alpha_, np.linalg.norm(w, 1)))
```

```
alpha = 9.867860e-06,    ||w||_1 = 20.221146
```



Mit Projected Gradient erhalten wir ein sehr ähnliches Resultat.

```
def l(w):  
    return 0.5 * ((X.dot(w) - y)**2).sum()  
  
def l1(w):  
    return X.T.dot(X.dot(w) - y)  
  
def GdP(w0, l1, pro, alpha = 1.0, nit = 10):  
    w = w0.copy()  
    w = pro(w)  
  
    ww = [w]  
  
    for k in range(nit):  
        w = w - alpha * l1(w)  
        w = pro(w)  
        ww.append(w)
```

```

return ww

w0 = np.zeros(X.shape[1])

r = 20
pro1 = lambda w : l1pro(w, r)

ww = GdP(w0, l1, pro = pro1, alpha = 0.5, nit = 500)



plt.figure()
plt.semilogy(list(map(l, ww)))
plt.xlabel('$k$')
plt.ylabel('$||Xw-y||_2^2$', rotation=0)

w = ww[-1]
plt.figure()
plotReko(w)

print('r = {:.f}'.format(r))

```

r = 20.000000



1.6 Zusammenfassung

Für Projected-Gradient-Descent bei restringierten Optimierungsproblemen mit $X \in \mathbb{R}^d$ abgeschlossen und konvex haben wir das selbe Konvergenzverhalten wie im nicht restringierten Fall nachgewiesen:

- f konvex und Lipschitz-stetig, $\gamma = \frac{c}{\sqrt{T}}$, $c > 0$:

$$\min_{t=0, \dots, T-1} (f_t - f_*) \leq \varepsilon \quad \Rightarrow \quad T = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$

- f konvex und L -glatt, $0 < \gamma < \frac{2}{L}$:

$$f_T - f_* \leq \varepsilon \quad \Rightarrow \quad T = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

- f μ -konvex mit $\mu > 0$ und L -glatt, $0 < \gamma \leq \frac{1}{L}$:

$$f_T - f_* \leq \varepsilon \quad \Rightarrow \quad T = \mathcal{O}\left(\log\left(\frac{1}{\varepsilon}\right)\right)$$

Das Berechnen der Projektion Π_X auf $X \in \mathbb{R}^d$ abgeschlossen und konvex kann extrem aufwendig sein. Für einige spezielle Mengen X die in der Praxis häufig auftreten lässt sich Π_X einfach berechnen.