

---

# 12\_Subgradient\_Descent

Martin Reißel

27. Juni 2022

## Inhaltsverzeichnis

<b>1 Subgradient Descent</b>	<b>1</b>
1.1 Überblick	1
1.2 Grundlagen	1
1.3 Vorüberlegungen	4
1.4 Lipschitz-Stetigkeit	4
1.5 L-Glattheit	5
1.6 $\mu$ -Konvexität	6
1.7 Zusammenfassung	8

## 1 Subgradient Descent

### 1.1 Überblick

Bisher haben wir immer  $f \in C^1(\mathbb{R}^d)$  vorausgesetzt. In der Praxis trifft das nicht immer zu (Lasso, RELU-MLP).

Ist  $f$  konvex, dann existiert in jedem Punkt der Subgradient. Wir benutzen jetzt bei Gradient Descent statt des (eventuell nicht existierenden) Gradienten einen Subgradienten.

Die fehlende Glattheit von  $f$  wird sich negativ auf die Konvergenzgeschwindigkeit auswirken.

### 1.2 Grundlagen

**Definition:**

- ist  $f : \mathbb{R}^d \supset \text{dom}(f) \rightarrow \mathbb{R}$ , dann ist  $g \in \mathbb{R}^d$  *Subgradient* von  $f$  in  $x \in \text{dom}(f)$ , falls

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in \text{dom}(f)$$

- die Menge aller Subgradienten von  $f$  an der Stelle  $x$  bezeichnen wir mit

$$\partial f(x) = \{g \mid g \text{ ist Subgradient von } f \text{ in } x\}$$

**Beispiel:** Ist  $f(x) = |x|$ , dann ist  $\partial f(0) = [-1, 1]$ , denn

$$|y| = f(y) \geq f(0) + g(y - 0) = gy \quad \forall y \in \mathbb{R}$$

genau dann wenn

$$g \in [-1, 1].$$

**Lemma:** Ist  $f$  differenzierbar in  $x$ , dann gilt  $\partial f(x) \subset \{f'(x)\}$ , also  $\partial f(x) = \{f'(x)\}$  oder  $\partial f(x) = \emptyset$ .

---

Die Ungleichung  $f(y) \geq f(x) + g^T(y - x)$  sieht aus wie die Konvexitätsbedingung für  $C^1$ -Funktionen, nur dass  $f'(x)$  durch  $g$  ersetzt wurde. Dies ist kein Zufall.

**Lemma:**  $f : \mathbb{R}^d \supset \text{dom}(f) \rightarrow \mathbb{R}$  ist konvex genau dann, wenn  $\text{dom}(f)$  konvex ist und

$$\partial f(x) \neq \emptyset \quad \forall x \in \text{dom}(f).$$

**Beweis:**

“ $\Rightarrow$ ”

- ist  $f$  konvex, so ist  $\text{epi}(f)$  konvex
- $\partial f(x) \neq \emptyset$  folgt aus dem [Existenzsatz für Stützhyperebenen](#) für konvexe Mengen angewandt auf  $\text{epi}(f)$

“ $\Leftarrow$ ”

- nach Voraussetzung ist  $\text{dom}(f)$  konvex und  $\partial f(x) \neq \emptyset$ , d.h. es existiert  $g(x) \in \partial f(x)$  mit

$$f(y) \geq f(x) + g(x)(y - x) \quad \forall x, y \in \text{dom}(f)$$

- für  $t \in [0, 1]$  setzen wir

$$z = (1 - t)x + ty$$

- dann ist  $z \in \text{dom}(f)$  und

$$f(x) \geq f(z) + g(z)(x - z)$$

$$f(y) \geq f(z) + g(z)(y - z)$$

- multiplizieren wir die erste Ungleichung mit  $1 - t$ , die zweite mit  $t$  und addieren die Ergebnisse, dann erhalten wir

$$\begin{aligned} (1 - t)f(x) + tf(y) &\geq (1 - t)(f(z) + g(z)(x - z)) \\ &\quad + t(f(z) + g(z)(y - z)) \\ &= f(z) + g(z) \underbrace{((1 - t)x + ty - z)}_z \\ &= f(z) \\ &= f((1 - t)x + ty) \end{aligned}$$

□

Existenz von Subgradienten und Konvexität sind also äquivalent.

Einige weitere Eigenschaften des Gradienten lassen sich auch auf Subgradienten übertragen. Für Lipschitz-Stetigkeit bei  $C^1$ -Funktionen  $f$  hatten wir  $\|f'(x)\| \leq L_f$ . Dies gilt analog auch für Subgradienten.

**Lemma:**  $f : \mathbb{R}^d \supset \text{dom}(f) \rightarrow \mathbb{R}$  konvex,  $\text{dom}(f)$  offen. Dann ist

$$\|f(x) - f(y)\| \leq L_f \|x - y\| \quad \forall x, y \in \text{dom}(f)$$

äquivalent zu

$$\|g\| \leq L_f \quad \forall g \in \partial f(x) \quad \forall x \in \text{dom}(f).$$

**Beweis:**

“ $\Rightarrow$ ”

- für  $x \in \text{dom}(f)$ ,  $g \in \partial f(x)$ ,  $\varepsilon > 0$  definieren wir

$$y = \begin{cases} x + \varepsilon \frac{g}{\|g\|} & g \neq 0 \\ x & g = 0 \end{cases}$$

- damit folgt

$$y - x = \begin{cases} \varepsilon \frac{g}{\|g\|} & g \neq 0 \\ 0 & g = 0 \end{cases}$$

bzw.

$$\|y - x\| = \begin{cases} \varepsilon & g \neq 0 \\ 0 & g = 0 \end{cases} \leq \varepsilon$$

- wegen  $\text{dom}(f)$  offen ist für  $\varepsilon > 0$  hinreichend klein auch  $y \in \text{dom}(f)$
- außerdem gilt

$$g^T(y - x) = \begin{cases} \varepsilon \frac{g^T g}{\|g\|} & g \neq 0 \\ 0 & g = 0 \end{cases} = \varepsilon \|g\|$$

- wegen  $g \in \partial f(x)$  ist dann

$$f(y) \geq f(x) + g^T(y - x) = f(x) + \varepsilon \|g\|$$

- da  $f$  Lipschitz-stetig ist folgt

$$L_f \varepsilon \geq L_f \|y - x\| \geq f(y) - f(x) \geq \varepsilon \|g\|,$$

also

$$\|g\| \leq L_f$$

“ $\Leftarrow$ ”

- für  $x, y \in \text{dom}(f)$  und  $g \in \partial f(x)$  gilt

$$f(y) \geq f(x) + g^T(y - x)$$

also

$$f(x) - f(y) \leq g^T(x - y)$$

- mit Cauchy-Schwartz und  $\|g\| \leq L_f$  folgt

$$f(x) - f(y) \leq \|g\| \|x - y\| \leq L_f \|x - y\|$$

- Vertauschen von  $x$  und  $y$  liefert schließlich

$$|f(x) - f(y)| \leq L_f \|x - y\| \quad \forall x, y \in \text{dom}(f)$$

□

**Satz:**  $f : \mathbb{R}^d \supset \text{dom}(f) \rightarrow \mathbb{R}$ ,  $x \in \text{dom}(f)$ , dann gilt

$$0 \in \partial f(x) \quad \Leftrightarrow \quad x \text{ ist globales Minimum von } f.$$

**Beweis:**

“ $\Rightarrow$ ”

- ist  $0 \in \partial f(x)$ , dann folgt aus der Definition des Subgradienten

$$f(y) \geq f(x) + 0^T(y - x) = f(x) \quad \forall y \in \text{dom}(f)$$

“ $\Leftarrow$ ”

- ist  $x \in \text{dom}(f)$  globales Minimum, dann gilt

$$f(y) \geq f(x) = f(x) + 0^T(y - x) \quad \forall y \in \text{dom}(f)$$

□

**Bemerkung:**

- die Bedingung  $0 \in \partial f(x)$  ist stärker als  $f'(x) = 0$  bei  $C^1$ -Funktionen
- $f'(x) = 0$  ist nur eine *notwendige Bedingung* für lokale Minima, d.h. aus  $f'(x) = 0$  alleine kann man i.A. nicht folgern, dass  $x$  ein lokales oder gar globales Minimum ist
- dagegen garantiert  $0 \in \partial f(x)$  immer, dass  $x$  globales Minimum ist

**1.3 Vorüberlegungen**

Wir betrachten nun *Subgradient-Descent*

$$x_{t+1} = x_t - \gamma_t g_t, \quad g_t \in \partial f(x_t).$$

Dabei ist  $g_t$  irgendein Element aus  $\partial f(x_t)$ .

Ist  $f$  konvex, dann ist  $\partial f(x) \neq \emptyset \quad \forall x$ , so dass immer mindestens ein  $g_t$  existiert.

Ist  $f$  konvex und in  $x_t$  differenzierbar, dann gilt

$$\partial f(x_t) = \{f'(x_t)\}$$

und somit

$$g_t = f'(x_t).$$

Wir lassen auch variable Schrittweite  $\gamma_t$  zu.

Unter diesen Voraussetzungen wollen wir analog zu Gradient-Descent die Konvergenzeigenschaften untersuchen. Viele Ergebnisse lassen sich direkt übertragen, indem man einfach  $f'_t$  durch  $g_t$  ersetzt.

Für Schrittweite  $\gamma$  erhalten wir damit

$$g_t^T (x_t - x_*) = \frac{1}{2\gamma} (\gamma^2 \|g_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2).$$

Da  $g_t$  Subgradient in  $x_t$  ist, gilt

$$f_* \geq f_t + g_t^T (x_* - x_t)$$

und somit

$$\begin{aligned} f_t - f_* &\leq g_t^T (x_t - x_*) \\ &= \frac{1}{2\gamma} (\gamma^2 \|g_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2). \end{aligned}$$

**1.4 Lipschitz-Stetigkeit**

Lipschitz-Stetigkeit von  $f$ , d.h.

$$\|f(y) - f(x)\| \leq L_f \|y - x\| \quad \forall x, y \in \mathbb{R}^d$$

ist äquivalent zu

$$\|g\| \leq L_f \quad \forall g \in \partial f(x) \quad \forall x \in \mathbb{R}^d.$$

Damit erhalten wir aus der letzten Ungleichung im vorherigen Abschnitt

$$f_t - f_* \leq \frac{1}{2\gamma} (\gamma^2 L_f^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2)$$

und somit

$$\begin{aligned} \sum_{t=0}^{T-1} (f_t - f_*) &\leq \frac{\gamma}{2} T L_f^2 + \frac{1}{2\gamma} \left( \underbrace{\|x_0 - x_*\|_2^2}_{e_0^2} - \underbrace{\|x_T - x_*\|_2^2}_{\geq 0} \right) \\ &\leq \frac{\gamma T L_f^2}{2} + \frac{e_0^2}{2\gamma}, \end{aligned}$$

was identisch ist mit der Abschätzung bei Gradient-Descent.

Somit erhalten wir in diesem Fall auch die selbe Konvergenzaussage wie bei Gradient-Descent.

**Satz:**  $f : \mathbb{R}^d \rightarrow \mathbb{R}$ , konvex,  $L$ -stetig mit Konstante  $L_f$  und es existiere  $x_* = \operatorname{argmin}_{x \in \mathbb{R}^d} f(x)$ . Mit  $\gamma = \frac{c}{T^\omega}$ ,  $\omega \in (0, 1)$ , gilt

$$\begin{aligned} \min_{t=0, \dots, T-1} (f_t - f_*) &\leq \frac{1}{T} \sum_{t=0}^{T-1} (f_t - f_*) \\ &= \mathcal{O}\left(\left(\frac{1}{T}\right)^{\min(\omega, 1-\omega)}\right) \quad \text{für } T \rightarrow \infty. \end{aligned}$$

Die optimale Ordnung ist  $\frac{1}{2}$  für  $\omega = \frac{1}{2}$ . Mit  $e_0 = \|x_0 - x_*\|$ ,  $\gamma = \frac{e_0}{L_f \sqrt{T}}$  gilt außerdem

$$\min_{t=0, \dots, T-1} (f_t - f_*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f_t - f_*) \leq \frac{L_f e_0}{\sqrt{T}}.$$

## 1.5 L-Glattheit

Bei differenzierbarem  $f$  hatten wir unter zusätzlichen Voraussetzungen ( $L$ -Glattheit,  $\mu$ -Konvexität) höhere Konvergenzraten nachweisen können.

Bei  $L$ -Glattheit stoßen wir hier auf ein Problem. Wie das folgende Lemma zeigt, sind  $L$ -glatte Funktionen mit existierenden Subgradienten automatisch differenzierbar.

**Lemma:**  $f : \mathbb{R}^d \supset \operatorname{dom}(f) \rightarrow \mathbb{R}$ ,  $\operatorname{dom}(f)$  offen und in  $x \in \operatorname{dom}(f)$  gelte  $\partial f(x) \neq \emptyset$ . Gibt es ein  $L \geq 0$  so dass für  $g_x \in \partial f(x)$

$$f(y) \leq f(x) + g_x^T(y - x) + \frac{L}{2} \|y - x\|_2^2 \quad \forall y \in \operatorname{dom}(f)$$

gilt, dann ist  $f$  differenzierbar in  $x$  und  $f'(x) = g_x$ .

**Beweis:**

- wegen  $g_x \in \partial f(x)$  gilt

$$f(y) \geq f(x) + g_x^T(y - x) \quad \forall y \in \operatorname{dom}(f)$$

und es folgt

$$0 \leq f(y) - (f(x) + g_x^T(y - x)) \leq \frac{L}{2} \|y - x\|_2^2$$

- also ist für  $y \rightarrow x$

$$|f(y) - (f(x) + g_x^T(y - x))| = \mathcal{O}(\|y - x\|)$$

und somit  $f$  in  $x$  differenzierbar mit Ableitung  $f'(x) = g_x$

□

Verlangen wir also  $L$ -Glattheit für subdifferenzierbare Funktionen (z.B.  $f$  konvex), so landen wir wieder beim differenzierbarem Fall.

## 1.6 $\mu$ -Konvexität

$\mu$ -Konvexität lässt sich einfach auf den subdifferenzierbaren Funktionen verallgemeinern.

**Definition:**  $f : \mathbb{R}^d \supset \text{dom}(f) \rightarrow \mathbb{R}$  heißt  $\mu$ -konvex, falls

$$f(y) \geq f(x) + g^T(y - x) + \frac{\mu}{2} \|y - x\|_2^2 \quad \forall g \in \partial f(x) \quad \forall x, y \in \text{dom}(f).$$

Wie im letzten Kapitel erklärt, müssen wir bei nicht differenzierbarem  $f$  auf  $L$ -Glattheit verzichten, was einige Schwierigkeiten verursachen wird.

Die Probleme die sich dabei ergeben werden wir am folgenden Beispiel näher untersuchen.

**Beispiel:**

- für die Funktion  $f : \mathbb{R} \rightarrow \mathbb{R}$

$$f(x) = e^{|x|} = \begin{cases} e^{-x} & x < 0 \\ e^x & 0 \leq x \end{cases}$$

erhalten wir als Subgradient

$$\partial f(x) = \begin{cases} \text{sign}(x) e^{|x|} & x \neq 0 \\ [-1, 1] & x = 0 \end{cases}$$

- $f$  ist  $\mu$ -konvex mit  $\mu = 1$  (Übung)
- $\mu$ -Konvexität liefert nur eine Schranke nach unten, d.h.  $f$  kann sehr stark wachsen und somit kann  $\partial f$  sehr große Werte annehmen
- ist dies der Fall, dann können bei Subgradient-Descent “Overshoots” auftreten
- um dies zu kompensieren und Konvergenz zu sichern, muss die Schrittweite  $\gamma$  sehr klein gewählt werden
- für “brave” Funktionen  $f$  verursacht das aber unnötigen Aufwand
- als Konsequenz muss die Schrittweite entsprechend an  $f$  angepasst werden

Beim einfachen Gradient-Descent hat die  $L$ -Glattheit (als Beschränkung nach oben) dieses Problem beseitigt. Da  $L$ -Glattheit hier nicht zur Verfügung steht, werden wir unter der zusätzlichen Annahme

$$\|g_t\| \leq B \quad \forall t$$

und  $t$ -abhängiger Schrittweite  $\gamma_t$  das folgende Konvergenz-Resultat für Subgradient-Descent beweisen.

**Satz:**  $f$  sei  $\mu$ -konvex und es existiere  $x_*$ . Für

$$\gamma_t = \frac{2}{\mu(t+1)}$$

erhalten wir für Subgradient-Descent

$$f\left(\underbrace{\frac{2}{T(T+1)} \sum_{t=1}^T tx_t}_{\text{Konvexkombination der } x_t}\right) - f_* \leq \frac{2B^2}{\mu(T+1)}$$

mit

$$B = \max_{t=1, \dots, T} \|g_t\|_2.$$

**Beweis:**

- aus den Vorüberlegungen wissen wir

$$g_t^T(x_t - x_*) = \frac{1}{2\gamma_t} (\gamma_t^2 \|g_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2)$$

- aus der  $\mu$ -Konvexität von  $f$  folgt mit  $y = x_*$ ,  $x = x_t$

$$f_* \geq f_t + g_t^T(x_* - x_t) + \frac{\mu}{2} \|x_* - x_t\|_2^2$$

also

$$f_t - f_* \leq g_t^T(x_t - x_*) - \frac{\mu}{2} \|x_t - x_*\|_2^2$$

und somit

$$\begin{aligned} f_t - f_* &\leq \frac{1}{2\gamma_t} (\gamma_t^2 \|g_t\|_2^2 + \|x_t - x_*\|_2^2 - \|x_{t+1} - x_*\|_2^2) - \frac{\mu}{2} \|x_t - x_*\|_2^2 \\ &\leq \frac{B^2}{2} \gamma_t + \frac{1}{2} \left( \frac{1}{\gamma_t} - \mu \right) \|x_t - x_*\|_2^2 - \frac{1}{2\gamma_t} \|x_{t+1} - x_*\|_2^2 \end{aligned}$$

- multiplizieren wir mit  $t$  und setzen wir wieder  $e_t = \|x_t - x_*\|_2$ , so erhalten wir

$$t(f_t - f_*) \leq \frac{t}{2} \left( \underbrace{B^2 \gamma_t + \left( \frac{1}{\gamma_t} - \mu \right) e_t^2}_{\alpha_t} - \underbrace{\frac{1}{\gamma_t} e_{t+1}^2}_{\beta_t} \right)$$

- Summation über  $t$  liefert

$$\begin{aligned} \sum_{t=1}^T t(f_t - f_*) &= \sum_{t=0}^T t(f_t - f_*) \\ &\leq \sum_{t=0}^T \frac{t}{2} (B^2 \gamma_t + \alpha_t e_t^2 - \beta_t e_{t+1}^2) \\ &= \frac{B^2}{2} \sum_{t=1}^T t \gamma_t + \frac{1}{2} \left( \sum_{t=0}^T t \alpha_t e_t^2 - \sum_{t=0}^T t \beta_t e_{t+1}^2 \right) \\ &= \frac{B^2}{2} \sum_{t=1}^T t \gamma_t + \frac{1}{2} \left( \sum_{t=0}^{T-1} (t+1) \alpha_{t+1} e_{t+1}^2 - \sum_{t=0}^T t \beta_t e_{t+1}^2 \right) \\ &= \frac{B^2}{2} \sum_{t=1}^T t \gamma_t + \frac{1}{2} \left( \sum_{t=0}^{T-1} ((t+1) \alpha_{t+1} - t \beta_t) e_{t+1}^2 - \beta_T e_{T+1}^2 \right) \\ &\leq \frac{B^2}{2} \sum_{t=1}^T t \gamma_t + \frac{1}{2} \left( \sum_{t=0}^{T-1} ((t+1) \alpha_{t+1} - t \beta_t) e_{t+1}^2 \right) \end{aligned}$$

- $\alpha_t$  und  $\beta_t$  hängen nur von  $\gamma_t$  und  $\mu$  ab
- kann man  $\gamma_t$  so wählen, dass

$$(t+1) \alpha_{t+1} - t \beta_t \leq 0 \quad \forall t \geq 0$$

gilt, dann kann der zweite Summand auf der rechten Seite mit 0 nach oben abgeschätzt werden

- für

$$\gamma_t = \frac{2}{\mu(t+1)}$$

ist

$$\begin{aligned} (t+1) \alpha_{t+1} - t \beta_t &= (t+1) \left( \frac{1}{\gamma_{t+1}} - \mu \right) - t \frac{1}{\gamma_t} \\ &= (t+1) \left( \frac{\mu(t+2)}{2} - \mu \right) - t \frac{\mu(t+1)}{2} \\ &= \frac{\mu}{2} (t+1)t - t \frac{\mu}{2} (t+1) \\ &= 0 \end{aligned}$$

und damit

$$\sum_{t=1}^T t(f_t - f_*) \leq \frac{B^2}{2} \sum_{t=1}^T t\gamma_t$$

- wegen

$$\frac{2}{T(T+1)} \sum_{t=1}^T t = 1,$$

der Konvexität von  $f$  und der Jensen-Ungleichung erhalten wir

$$\begin{aligned} f\left(\frac{2}{T(T+1)} \sum_{t=1}^T tx_t\right) - f_* &\leq \left(\frac{2}{T(T+1)} \sum_{t=1}^T tf_t\right) - f_* \\ &= \frac{2}{T(T+1)} \sum_{t=1}^T t(f_t - f_*) \\ &\leq \frac{B^2}{T(T+1)} \sum_{t=1}^T t\gamma_t \end{aligned}$$

- mit

$$\gamma_t = \frac{2}{\mu(t+1)}$$

folgt

$$\sum_{t=1}^T t\gamma_t = \frac{2}{\mu} \sum_{t=1}^T \frac{t}{t+1} \leq \frac{2}{\mu} T$$

und somit schließlich

$$f\left(\frac{2}{T(T+1)} \sum_{t=1}^T tx_t\right) - f_* \leq \frac{2B^2}{\mu(T+1)}$$

□

#### Bemerkung:

- in der oberen Schranke steckt  $x_0$  nicht explizit drin, geht aber implizit über  $B$  ein ( $\|g_t\|_2 \leq B \forall t$ )
- für  $f$  differenzierbar,  $\mu$ -konvex und  $L$ -glatt hatten wir bei Gradient-Descent die Komplexität  $\mathcal{O}\left(\log\left(\frac{1}{\varepsilon}\right)\right)$
- für  $f$   $\mu$ -konvex,  $\|g_t\|_2 \leq B \forall t$  bekommen wir bei Subgradient-Descent nur die Komplexität  $\mathcal{O}\left(\frac{1}{\varepsilon}\right)$ , d.h. aus fehlender Glattheit von  $f$  kann wieder langsamere Konvergenz folgen

## 1.7 Zusammenfassung

Ist  $f$  konvex und nicht differenzierbar, dann benutzt man bei Gradient-Descent statt des (eventuell nicht existierenden) Gradienten einen Subgradienten.

Für das *nicht restringierte Optimierungsproblem* haben wir folgendes Konvergenzverhalten nachgewiesen:

- $f$  konvex und Lipschitz-stetig,  $\gamma = \frac{c}{\sqrt{t}}$ ,  $c > 0$ :

$$\min_{t=0,\dots,T-1} (f_t - f_*) \leq \frac{L_f e_0}{\sqrt{T}}$$

also

$$\min_{t=0,\dots,T-1} (f_t - f_*) \leq \varepsilon \quad \Rightarrow \quad T = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$$



- $f$   $\mu$ -konvex mit  $\mu > 0$  und  $\|g_t\| \leq B$ ,  $\gamma_t = \frac{2}{\mu(t+1)}$

$$f\left(\frac{2}{T(T+1)} \sum_{t=1}^T tx_t\right) - f_* \leq \frac{2B^2}{\mu(T+1)},$$

also

$$f\left(\frac{2}{T(T+1)} \sum_{t=1}^T tx_t\right) - f_* \leq \varepsilon \quad \Rightarrow \quad T = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$$

Im ersten Fall benötigen wir für Genauigkeit  $\varepsilon$  den selben asymptotischen Aufwand wie bei differenzierbarem  $f$ .

Im zweiten Fall steigt der Aufwand von  $\mathcal{O}\left(\log\left(\frac{1}{\varepsilon}\right)\right)$  auf  $\mathcal{O}\left(\frac{1}{\varepsilon}\right)$ , d.h. durch die reduzierten Glattheitsanforderungen an  $f$  reduziert sich hier die Konvergenzgeschwindigkeit.